TD de révision : SQL

Jointures, requêtes imbriquées, CTEs, fonctions d'agrégation

2026-10-09

Avec solutions

L3 MIASHS
Université Paris Cité
Année 2025
Course Homepage
Moodle

Objectifs

Réviser les notions de SQL et d'Algèbre relationnelle vues dans le cours et les TDs précédents :

- jointures,
- requêtes imbriquées,
- fonctions d'agrégation.

Prérequis

- schéma `NYCflights`,
- cours Algèbre relationnelle,
- cours Requêtes simples et jointures,
- cours Requêtes imbriquées, CTEs,
- cours Agrégation, Partitions, Fenêtres.

Les questions qui suivent concernent le schéma `nycflights`. Il est donc nécessaire de changer le `search_path` pour inclure le schéma `nycflights`.

Questions

1. Afficher tous les détails des avions du fabricant 'BOEING' qui disposent d'au moins 300 places (au sens strict) ? (144 lignes) Ecrire la requête en SQL et en algèbre relationnelle.

Solution

Algèbre relationnelle :
$\texttt{R} = \sigma(\texttt{planes},\ \texttt{manufacturer = 'BOEING'}\ \wedge\ \texttt{seats >= 300})$

```sql
select *
From planes p
where manufacturer ilike 'BOEING' and seats >= 300;
```

2. Afficher les identifiants et les modèles des avions du fabricant 'AIRBUS INDUSTRIE' fabriqués strictement avant 2000 (attribut `year`) ou de moteur de type 'Turbo-jet' (attribut `engine`) ? (273 lignes) Ecrire la requête en SQL et en algèbre relationnelle.

Solution

Algèbre relationnelle :
R1 = σ(planes, manufacturer = 'AIRBUS INDUSTRIE' $\wedge$ (year < 2000 $\vee$ engine = 'Turbo-jet')) R = Π(R1, tailnum, model)

```
select tailnum, model
From planes
where manufacturer ilike 'AIRBUS INDUSTRIE' and (year < 2000 or engine ilike 'Turbo-jet');
```

3. Quels sont les avions (identifiant, modèle) du fabricant 'CANADAIR' qui ont volé en janvier 2013 ? (8 lignes) Ecrire la requête en SQL et en algèbre relationnelle.

Solution

Algèbre relationnelle :
R1 = σ(planes $\bowtie_{\text{tailnum}}$ flights, planes.manufacturer = 'CANADAIR' $\wedge$ flights.year = 2013 $\wedge$ flights.month = 1) R = Π(R1, tailnum, model)

```
select distinct tailnum, model
from planes p JOIN
   flights f USING (tailnum)
where manufacturer ilike 'CANADAIR' and f.year = 2013 and f.month = 1 ;
```

4. Quels sont les avions (identifiant et modèle) de la table `planes` qui n'ont pas volé en janvier 2013 ? (713 lignes) Proposer plusieurs solutions. Ecrire les requêtes en SQL et en algèbre relationnelle.

Solution

Algèbre relationnelle avec une jointure externe :
$\texttt{R1} = \sigma(\texttt{flights},\ \texttt{year = 2013} \wedge \texttt{month = 1})$
$\texttt{R2} = \sigma(\texttt{planes}\ ^{+}\bowtie_{\texttt{tailnum}} \texttt{R1},\ \texttt{R1.tailnum = NULL})$
$\texttt{R} = \Pi(\texttt{R2},\ \texttt{tailnum},\ \texttt{model})$
Algèbre relationnelle avec une opération de différence :
$\texttt{R1} = \sigma(\texttt{planes} \bowtie_{\texttt{tailnum}} \texttt{flights},\ \texttt{year = 2013} \wedge \texttt{month = 1})$ $\texttt{R} = \Pi(\texttt{planes},\ \texttt{tailnum},\ \texttt{model}) \setminus \Pi(\texttt{R1},\ \texttt{tailnum},\ \texttt{model})$
Avec une jointure externe :

```sql
with planes_janv_2013 as(
   select distinct tailnum from flights
   where year = 2013 and month = 1
)
select p.tailnum, p.model
from planes p left join planes_janv_2013 pj13 using(tailnum)
where pj13.tailnum is NULL;
```

Avec une différence :

```sql
with planes_janv_2013 as(
   select p.tailnum, p.model
   from flights f join planes p using(tailnum)
   where f.year = 2013 and f.month = 1
)
(select tailnum, model from planes)
except
(select tailnum, model from planes_janv_2013);
```

Avec `NOT EXISTS` :

```sql
select tailnum, model
from planes
where not exists (
   select 1
   from flights
   where flights.tailnum = planes.tailnum
   and flights.year = 2013 and flights.month = 1
);
```

Solution **erronée** avec `NOT IN` à cause de la logique trivalente car NULL est présent dans la sous-requête (vols annulés). La table retournée est donc vide. Il faut utiliser `NOT EXISTS`, une différence ou une jointure externe comme ci-dessus.

```sql
select tailnum, model
from planes
where tailnum not in (
   select distinct tailnum
   from flights
   where year = 2013 and month = 1
)
```

Solution **correcte** avec `NOT IN` en excluant les valeurs `null` du résultat de la sous-requête :

```sql
select tailnum, model
from planes
where tailnum not in (
   select distinct tailnum
   from flights
   where year = 2013 and month = 1 and tailnum is not null
);
```

5. Quels sont les avions (identifiants, modèles) de la table `planes` qui ont volé le 5 et le 6 janvier ? (210 lignes) Proposer plusieurs solutions. Ecrire la requête en SQL et en algèbre relationnelle.

Solution

Algèbre relationnelle avec une jointure :
$R1 = \sigma(planes \bowtie_{tailnum} flights, flights.year = 2013 \wedge flights.month = 1 \wedge flights.day = 5)$ $R2 = \sigma(planes \bowtie_{tailnum} flights, flights.year = 2013 \wedge flights.month = 1 \wedge flights.day = 6)$ $R = \Pi(R1 \bowtie_{tailnum} R2, R1.tailnum, R1.model)$
Algèbre relationnelle avec une intersection :
$R1 = \sigma(planes \bowtie_{tailnum} flights, flights.year = 2013 \wedge flights.month = 1 \wedge flights.day = 5)$ $R2 = \sigma(planes \bowtie_{tailnum} flights, flights.year = 2013 \wedge flights.month = 1 \wedge flights.day = 6)$ $R = \Pi(R1, tailnum, model) \cap \Pi(R2, tailnum, model)$
SQL avec une jointure :

```sql
with planes_5_janv_2013 as(
   select p.tailnum, p.model
   from flights f join planes p using(tailnum)
   where f.year = 2013 and f.month = 1 and f.day = 5
),
planes_6_janv_2013 as(
   select p.tailnum, p.model
   from flights f join planes p using(tailnum)
   where f.year = 2013 and f.month = 1 and f.day = 6
)
select distinct p5.tailnum, p5.model
from planes_5_janv_2013 p5 join planes_6_janv_2013 p6 using(tailnum);
```

SQL avec une intersection :

```sql
with planes_5_janv_2013 as(
   select p.tailnum, p.model
   from flights f join planes p using(tailnum)
   where f.year = 2013 and f.month = 1 and f.day = 5
),
planes_6_janv_2013 as(
   select p.tailnum, p.model
   from flights f join planes p using(tailnum)
   where f.year = 2013 and f.month = 1 and f.day = 6
)
(select * from planes_5_janv_2013)
intersect
(select * from planes_6_janv_2013);
```

6. Quels sont les avions (identifiants, modèles) de la table `planes` qui ont eu au moins un retard à l'arrivée en 2013 ? (3176 lignes) Un vol retardé à l'arrivée est un vol dont l'attribut `arr_delay` est strictement supérieur à 0. Proposer plusieurs solutions.

Solution

NB : la valeur `NULL` est interdite sur la colonne `tailnum` de la table `planes` (clé primaire) mais pas sur la colonne `tailnum` de la table `flights`.
Avec une jointure :

```
with delayed_2013 as(
   select distinct tailnum
   from flights
   where arr_delay > 0 and year = 2013
)
select p.tailnum, p.model
from planes p join delayed_2013 d using(tailnum);
```

Avec `IN` (le résultat de la sous-requête peut contenir `NULL`) :

```
with delayed_2013 as(
   select distinct tailnum
   from flights
   where arr_delay > 0 and year = 2013
)
select tailnum, model
from planes
where tailnum in (select * from delayed_2013);
```

Avec `EXISTS`

```
with delayed_2013 as(
   select distinct tailnum
   from flights
   where arr_delay > 0 and year = 2013
)
select tailnum, model
from planes p
where exists (
   select 1
   from delayed_2013 d
   where d.tailnum = p.tailnum);
```

7. Quels sont les avions (identifiants, modèles) de la table `planes` qui n'ont pas eu de retard à l'arrivée en 2013 ? (146 lignes) Proposer plusieurs solutions.

Solution

Attention : la valeur `NULL` est interdite sur la colonne `tailnum` de la table `planes` (clé primaire) mais pas sur la colonne `tailnum` de la table `flights`.
Avec une jointure externe :

```
with delayed_2013 as(
   select distinct tailnum
   from flights
   where arr_delay > 0 and year = 2013
)
select p.tailnum, p.model
from planes p left join delayed_2013 d using(tailnum)
where d.tailnum is NULL;
```

Avec une différence :

```
with delayed_2013 as(
   select distinct tailnum
   from flights
   where arr_delay > 0 and year = 2013
),
not_delayed_2013 as(
   select tailnum from planes
   except
   select tailnum from delayed_2013
)
select p.tailnum, p.model
from planes p join not_delayed_2013 using(tailnum);
```

Avec `NOT IN` (en retirant `NULL` des résultats de la sous-requête car `NULL` est autorisé pour `tailnum` dans `flights`)

```
with delayed_2013 as(
   select distinct tailnum
   from flights
   where tailnum is not null and arr_delay > 0 and year = 2013
)
select tailnum, model
from planes
where tailnum not in (
   select tailnum from delayed_2013
)
```

8. Quels sont les fabricants dont aucun avion de la table `planes` n'a eu un retard à l'arrivée en 2013 ? (0 ligne) Proposer plusieurs solutions.

Solution

Attention, la valeur `NULL` n'est pas interdite sur la colonne `manufacturer`.
On peut faire la différence avec une jointure externe :

```
with manufacturer_delayed_2013 as(
   select distinct p.manufacturer
   from flights f join planes p using(tailnum)
   where f.arr_delay > 0 and f.year = 2013
)
select distinct p.manufacturer
from planes p natural left join manufacturer_delayed_2013 d
where d.manufacturer is null;
```

Ici, les valeurs `NULL` de `planes.manufacturer` ou de `manufacturer_delayed_2013` sont exclues par l'équijointure de la requête principale car si au moins un des membres d'un test d'égalité est `NULL`, le test n'est pas `True`.
Ou avec `EXCEPT`

```
with manufacturer_delayed_2013 as(
   select distinct p.manufacturer
   from flights f join planes p using(tailnum)
   where f.arr_delay > 0 and f.year = 2013
)
(
   select manufacturer
   from planes
   where manufacturer is not null
)
except
select manufacturer from manufacturer_delayed_2013;
```

Ici, les valeurs `NULL` de `planes.manufacturer` ne sont pas exclues par `EXCEPT` car les opérations ensemblistes traitent les valeurs `NULL` comme les autres. On ajoute donc une condition pour les exclure.
Ou encore avec `NOT IN` en excluant de la sous-requête les valeurs `NULL` :

```
with manufacturer_delayed_2013 as(
   select distinct p.manufacturer
   from flights f join planes p using(tailnum)
   where p.manufacturer is not null and f.arr_delay > 0 and f.year = 2013
)
select distinct manufacturer
from planes
where manufacturer not in (
   select *
   from manufacturer_delayed_2013
);
```

Cette requête n'est pas correcte : elle donne la liste des fabricants dont au moins un avion n'a jamais eu de retard à l'arrivée en 2013

```
with delayed_2013 as(
   select distinct tailnum
   from flights
   where arr_delay > 0 and year = 2013
)
select distinct p.manufacturer
from planes p left join delayed_2013 d using(tailnum)
where d.tailnum is NULL;
```

9. Quelle est la capacité maximale d'un avion de la table `planes` ? (450 places)

Solution

```
select max(seats)
from planes;
```

10. Combien d'avions de la table `planes` ont volé en janvier 2013 ? (2609)

Solution

```
select count(distinct p.tailnum)
from flights f join planes p using(tailnum)
where f.year = 2013 and f.month = 1;
```

11. Combien y-a-t-il eu de vols en janvier 2013 pour les avions de la table `planes` de capacité supérieure ou égale à 300 ? (377)

Solution

```
select count(*)
from flights f join planes p using(tailnum)
where f.year = 2013 and f.month = 1 and p.seats >=300 ;
```

12. Quels sont les aéroports de la table `airports` (identifiants, noms) qui ont au moins 100 vols annulés au départ en 2013 ? (3 lignes) Dans la table `flights`, les vols annulés sont caractérisés par une valeur `NULL` dans la colonne `tailnum` et l'aéroport de départ est indiqué dans la colonne `origin`. On indiquera le nombre de vols annulés pour chaque ligne.

Solution

```
select a.faa, a.name, count(f.*)
from airports a join flights f on a.faa = f.origin
where tailnum is null and year = 2013
group by a.faa, a.name
having count(f.*)>=10;
```

13. Quelle est la proportion des vols de la table `flights` en 2013 qui ont été retardés à l'arrivée, la proportion se rapporte à tous les vols, y compris les vols annulés ? (39,49 %) Attention, il faut penser à convertir les entiers en nombres à virgule avant de faire la division, car la division entre entiers retourne le quotient entier. Pour convertir par exemple dans le type `numeric`, on peut utiliser la fonction `cast` ou l'opérateur `::`. Par exemple, `cast(1 as numeric)` ou `1::numeric` convertit l'entier 1 en nombre à virgule.

Solution

```
with nb_delayed_2013 as(
   select count(*) as nb_delayed
   from flights
   where arr_delay is not null and arr_delay > 0 and year = 2013
),
nb_flighs_2013 as(
   select count(*) as nb_flights
   from flights
   where year = 2013
)
select round(100*nb_delayed::numeric/nb_flights::numeric,2) as percentage_delayed
from nb_delayed_2013, nb_flighs_2013;
```

14. Quels sont les aéroports de la table `airports` (identifiants, noms) qui ont au plus 10 vols retardés à l'arrivée en 2013 ? (6 lignes) L'aéroport d'arrivée est celui qui est indiqué dans la colonne `dest` de la table `flights`.

Solution

```
select a.faa, a.name
from airports a join flights f on a.faa = f.dest
where arr_delay is not null and arr_delay > 0 and year = 2013
group by a.faa, a.name
having count(f.*)>=10;
```

15. Quelle est, par aéroport de la table `airports` et par mois, la moyenne des retards à l'arrivée des vols de l'année 2013 ? On veut afficher les identifiants et les noms d'aéroport, les résultats doivent être triés par nom d'aéroport puis par mois. On ne calcule la moyenne des retards à l'arrivée que pour les vols non annulés et retardés à l'arrivée (arr_delay > 0). La première ligne est `CAK  Akron Canton Regional Airport  1  30.75`

Solution

```
select a.faa, a.name,  f.month, avg(arr_delay) as avg_arr_delay
from airports a join flights f on a.faa = f.dest
where arr_delay is not null and arr_delay > 0 and year = 2013
group by a.faa, a.name, f.month
order by a.name, f.month;
```

16. Quels sont les mois de l'année 2013 où le nombre de vols de la table `flights` retardés à l'arrivée sont parmi les 3 plus élevés ? Résultat attendu : 3 lignes (mois 12, 7 et 4).

Solution

```
select month, count(*) as nb_arr_delay
from flights
where arr_delay is not null and arr_delay > 0 and year = 2013
group by month
order by nb_arr_delay desc
limit 3;
```

17. Quels sont les aéroports de la table `airports` (identifiants, noms) qui ont au moins 10 vols retardés à l'arrivée sur un des mois de l'année 2013 ? (91 lignes)

Solution

```
select distinct a.faa, a.name
from airports a join flights f on a.faa = f.dest
where arr_delay is not null and arr_delay > 0 and year = 2013
group by a.faa, a.name, f.month
having count(f.*)>=10;
```

18. Y-a-t-il une corrélation entre les retards des vols à l'arrivée et la lattitude des aéroports d'arrivée (sont-ils plus au nord ou plus au sud que la moyenne) ? On veut étudier cette correlation en calculant l'écart entre la latitude moyenne des aéroports d'arrivée dont la moyenne des retards est supérieure à la moyenne des retards des vols, et la latitude moyenne de tous les aéroports d'arrivée.

Il faut calculer les moyennes sur les mêmes ensembles. Comme il y a des aéroports de la tables `flights` qui ne sont pas référencés dans la table `airports`, il faut limiter tous les calculs à l'ensemble des aéroports présents dans la table `airports`.
De plus, on veut faire les moyennes des retards sur tous les vols non annulés (`arr_delay` non `NULL`), en remplaçant les valeurs négatives de `arr_delay` (vols arrivés en avance) par 0.
Réponse : `-3.5606983858561545`
Le retard moyen calculé selon la méthode indiquée est de `16.482925746304826`.

Solution

Bien que la fonction `AVG` ne calcule la maoyenne que sur les valeurs non `NULL`, il est préférable de gérer explicitement les valeurs `NULL`, surtout si cela correspond à une condition exigée sur la sélection des lignes (non annulation des vols).

```
with avg_lat as(
   select avg(lat) avg_lat
   from airports
),
avg_arr_delay as(
   select avg(case
      when f.arr_delay < 0 then 0
      else f.arr_delay
    end) avg_delay
   from flights f join airports a on a.faa = f.dest
   where f.arr_delay is not null
),
avg_arr_delay_per_airport as(
   select a.faa, a.name, a.lat,
   avg (case
      when arr_delay < 0 then 0
      else arr_delay
    end) avg_delay
   from airports a join flights f on a.faa = f.dest
   where year = 2013
   group by a.faa, a.name, a.lat
)
select avg(lat-al.avg_lat)
from avg_arr_delay_per_airport adpa, avg_arr_delay ad, avg_lat al
where adpa.avg_delay > ad.avg_delay;
```